Big Data Analytics Programming

Week-01. 학습환경 설정

Jungwon Seo, 2020-Fall

수업에 사용되는 툴/서비스

- Yscec: 이론 강의 영상 업로드 외 성적제출용
- Github: 모든 강의 리소스가 공유되는 지점
- Shell: Windows는 Gitbash, macos는 terminal
- Slack: 커뮤니케이션 툴
- Kahoot: 실시간 퀴즈/설문 조사를 위한 툴
- Cohoot: 강사가 개발하고 있는 실시간 코드 공유 툴
- Anaconda: 파이썬 통합 패키지 소프트웨어
- Jupyter notebook: 통합개발환경 (a.k.a, 코드에디터)
- AWS: 웹서버 배포 또는 데이터 베이스 활용을 위한 클라우드 서비스

Shell

운영체제의 서비스에 접근하기 위한 유저 인터페이스

- Command Line Interface
  - 텍스트 명령어로 컴퓨터에 동작을 실행하는 인터페이스
  - 우리가 마우스를 클릭해서 동작을 실행할 수 있는 인터페이스는 Graphical User Inteface
- 이러한 CLI를 제공하는 환경을 Shell 또는 Command Line Interpreter라고 불리움
- WIndows와 다른 운영체제와의 CLI 명령어가 다르기 때문에, Windows에서는 **gitbash**라는 프로그램으로 Shell명령어를 사용한다.
  *모두가 그렇다는건 아니고 이번 수업에서만

최초의 매킨토시는 그래픽 사용자 인터페이스,
내장 스크린 및 마우스를 특징으로하는
최초의 대중 시장 개인용 컴퓨터입니다.

https://en.wikipedia.org/wiki/Macintosh_128K#/media/File:Macintosh_128k_transparency.png

Shell
예시화면

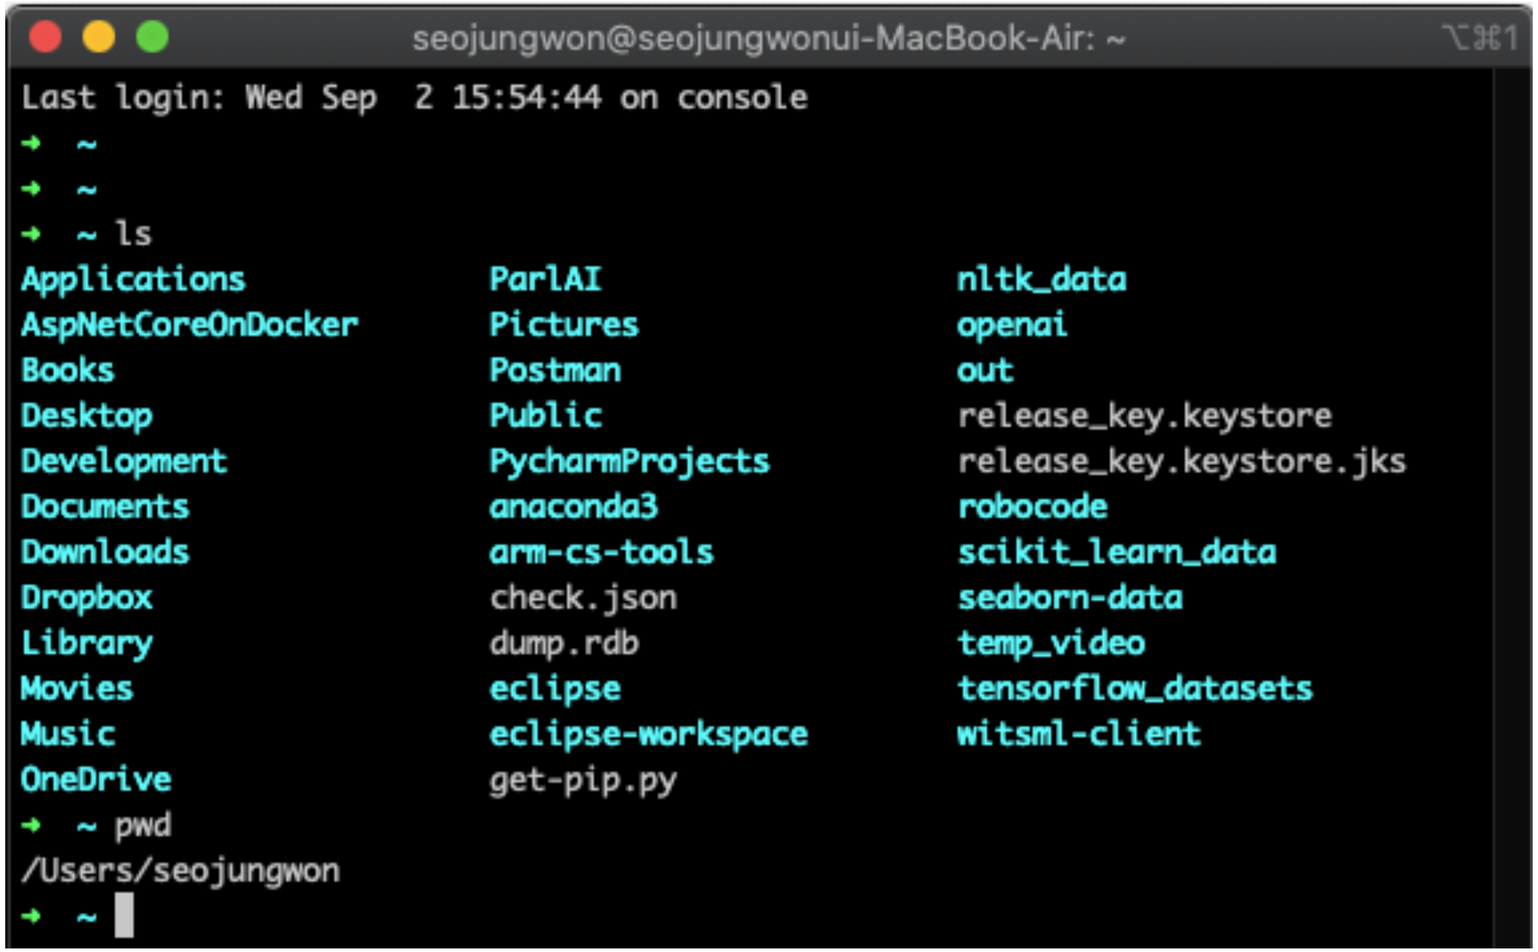
seojungwon@seojungwonui-MacBook-Air: ~
⌥⌘1
Last login: Wed Sep 2 15:54:44 on console
→ ~
→ ~
→ ~ ls
Applications
AspNetCoreOnDocker
Books
Desktop
Development
Documents
Downloads
Dropbox
Library
Movies
Music
OneDrive
ParlAI
Pictures
Postman
Public
PycharmProjects
anaconda3
arm-cs-tools
check.json
dump.rdb
eclipse
eclipse-workspace
get-pip.py
nltk_data
openai
out
release_key.keystore
release_key.keystore.jks
robocode
scikit_learn_data
seaborn-data
temp_video
tensorflow_datasets
witsml-client
→ ~ pwd
/Users/seojungwon
→ ~

Shell

자주 사용되는 명령어

- ls : 현재 위치한 폴더에 존재하는 파일/폴더 출력
- cd <위치> : 특정 폴더로 이동
- pwd : root directory 기준으로 현재 위치 출력
- vi <파일이름>: vi editor를 이용하여, 텍스트 작업
- mkdir <폴더이름> : 폴더 생성
- touch <파일이름> : 파일 생성
- rm <파일이름> : 파일 삭제

Github

분산 버전 관리 툴인 깃(Git)을 사용하는 프로젝트를 지원하는 웹호스팅 서비스

- Git:
  - 컴퓨터 파일의 변경사항을 추적하고 여러 명의 사용자들 간에 해당 파일들의 작업을 조율하기 위한 분산 버전 관리 시스템
  - 깃은 2005년에 리눅스 커널 개발을 위해 초기 개발에 기여한 다른 커널 개발자들과 함께 2005년에 **리누스 토르발스**가 처음 개발
  - 버전관리를 제대로 하지 않으면… *test1.py, test2.py, test_final.py, test_real_final.py, test_final_final.py*
- Github:
  - Git을 웹상에서 호스팅 해주는 서비스
  - 즉, Github 외에도 Git을 웹서비스로 제공하는 서비스가 더 있다. (Gitlab, Bitbucket ..)
  - 2018년 10월에 마이크로 소프트에 인수

Github
주요 구조

- Repository (저장소):
  - 간단하게 말하면, 하나의 프로젝트 폴더
  - 이 폴더(저장소)를 기준으로, 폴더 내에 있는 파일 또는 폴더들이 버전관리가 가능
  - 즉, test.py, test_v2.py 이런식으로 만들지 않아도, 같은 파일에 수정을 한뒤 git 명령어를 활용해 push를 하면, 자동으로 push 시점에 대한 버전이 생성됨
- Organization:
  - 기본적으로 개인용 Repository를 사용하지만, 팀 단위로 개인 Repository에 작업을 하는 것은 바람직하지 않음.
  - 또한 프로덕트당 Repository가 필요하기 때문에, 이들을 그룹지어 놓을 수 있는 단위가 필요함
  - 페이스북 그룹과 비슷한 느낌

Github
README 파일

- README.md:
  - 간단하게 말해서, 해당 Repository 또는 폴더의 메인페이지와 같은 역할을 함.
  - README라는 예약어로, 깃허브 내에서는 자동으로 현재 디렉토리의 이 파일을 호출함
  - 만약 test.MD라는 형태로 저장을 하면, 이것은 일반 파일과 같게 취급
  - 작성 포맷은 Markdown이라는 markup-language를 사용

렌더링 된 모습

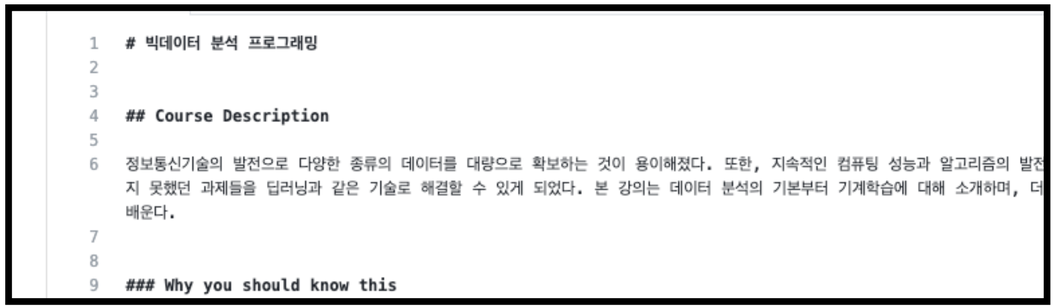

```
# 빅데이터 분석 프로그래밍


## Course Description

정보통신기술의 발전으로 다양한 종류의 데이터를 대량으로 확보하는 것이 용이해졌다. 또한, 지속적인 컴퓨팅 성능과 알고리즘의 발전
지 못했던 과제들을 딥러닝과 같은 기술로 해결할 수 있게 되었다. 본 강의는 데이터 분석의 기본부터 기계학습에 대해 소개하며, 더
배운다.


### Why you should know this
```

실제 작성된 내용

Github
사용시나리오 #1

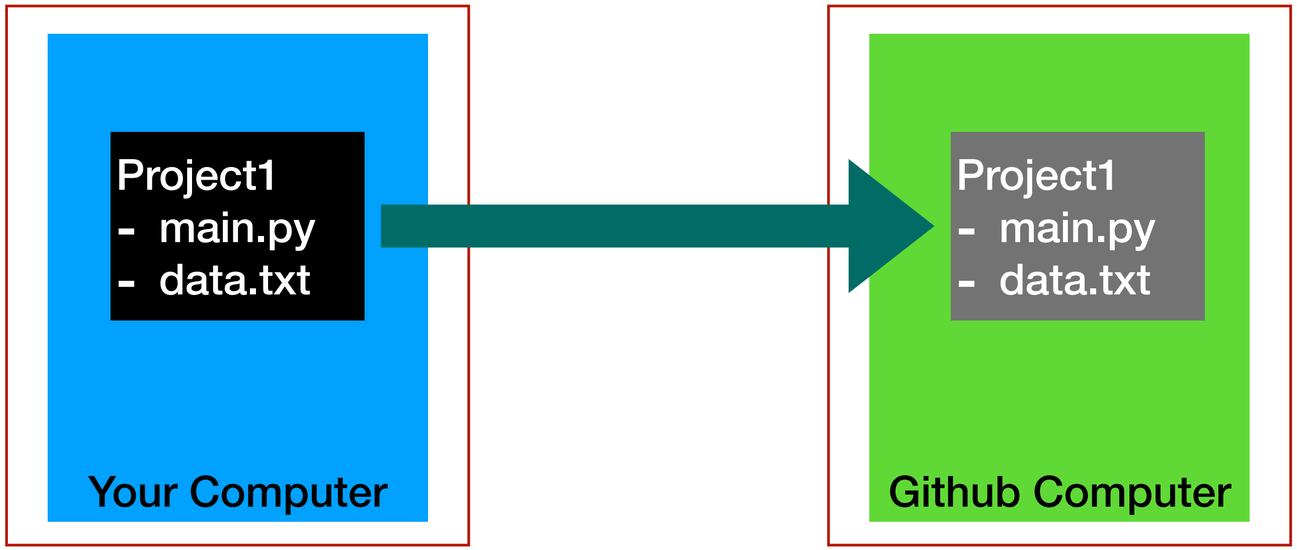

- Local에서 Remote로
- Shell 명령어
  - cd Project1 (Project1 폴더로 이동)
  - echo "# test" >> README.md (README.md 파일 생성)
  - git init (폴더가 git 환경을 갖출수 있도록 초기화)
  - **git add .** (폴더 내에 있는 모든 파일을 staging area 에 추가)
  - **git commit -m "my first commit”** (변경된 내용을 Local Repository에 추가)
  - git branch -M master (최초에만 실행, 현재 브랜치를 마스터로 설정)
  - git remote add origin https://github.com/thejungwon/project1.git (Remote 저장소 지정)
  - **git push -u origin master** (Remote 저장소에 배포)

Github
사용시나리오 #2

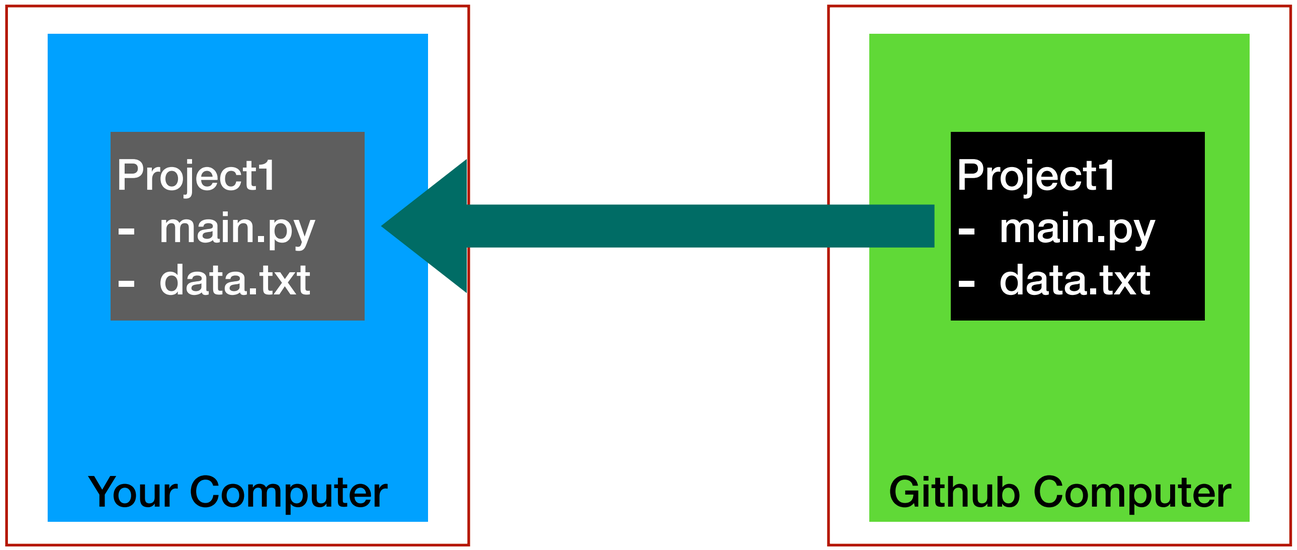

- Remote에서 Local로
- Shell 명령어
  - cd Projects (Project1을 받을 상위 폴더로 이동)
  - **git clone https://github.com/thejungwon/project1.git** (local로 복제)
  - cd project1
  - 무언가 변경을 한다!
  - **git add .** (폴더 내에 있는 모든 변경된 파일을 staging area 에 추가)
  - **git commit -m "my first commit”** (변경된 내용을 Local Repository에 추가)
  - **git push -u origin master** (Remote 저장소에 배포)

Anaconda

패키지 관리와 배포를 단순케 할 목적으로 파이썬과 R 프로그래밍 언어의 무료-오픈 소스 배포판

- 파이썬에 대한 패키지 관리 및 데이터 과학을 위한 각종 툴을 종합적으로 모아서 제공
  - 각각의 패키지, 언어, 소프트웨어를 따로 설치하고 환경 설정을 하는 수고를 덜 수 있음

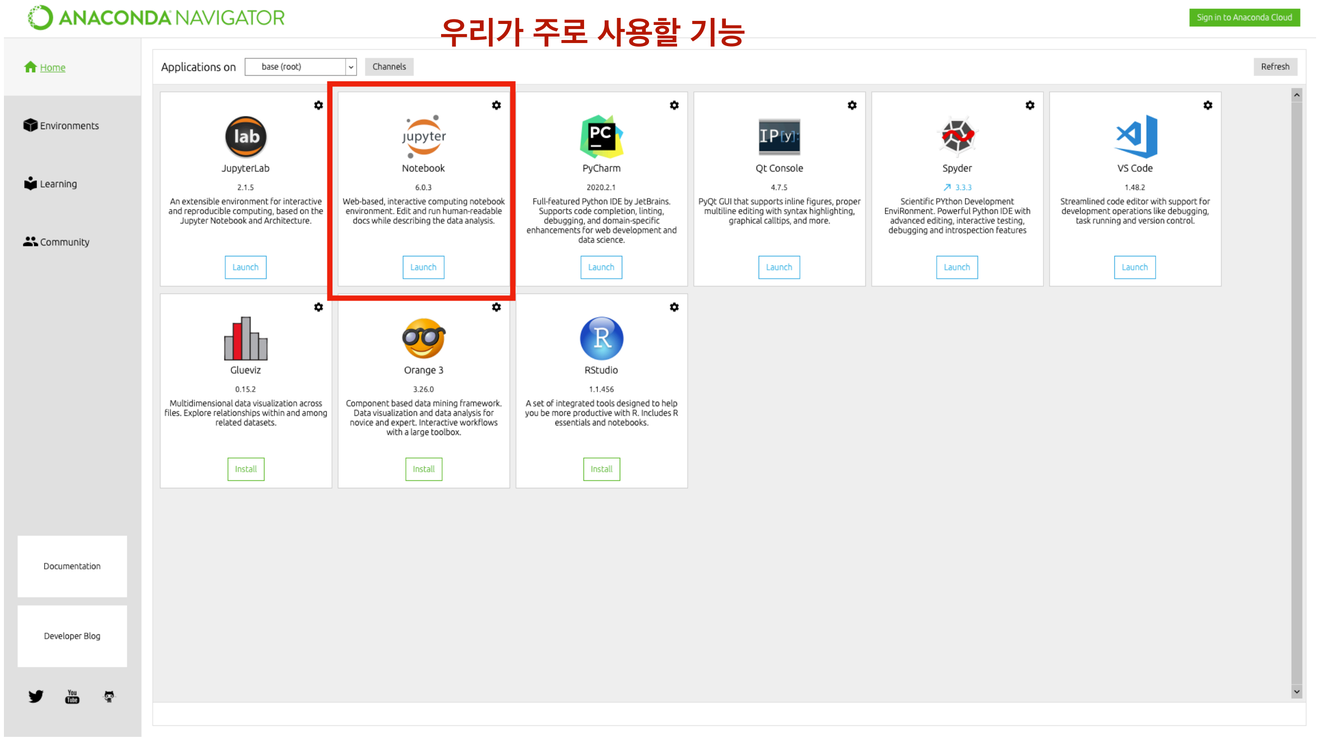

Jupyter Notebook

라이브 코드, 방정식, 시각화 및 설명 텍스트가 포함 된 문서를 만들고 공유 할 수있는 오픈 소스 웹 애플리케이션

- 데이터 사이언스에 적합한 통합개발환경(IDE)
  - 일반 IDE (e.g., visual studio code, atom, pycharm 등)은 코드 작성에만 치중되어있고, 저장후 파일 전체를 실행시켜야만 함.
  - 각각의 함수 또는 로직이 **오래걸리는** 데이터 사이언스의 코딩 방식에는 적합하지 않음
  - **Interactive** 하게 셀(cell) 단위로 코드를 실행할 수 있음
  - 일반적으로 배포 전, 개발 및 모델 작성 과정에서는 주피터 노트북을 주로 활용

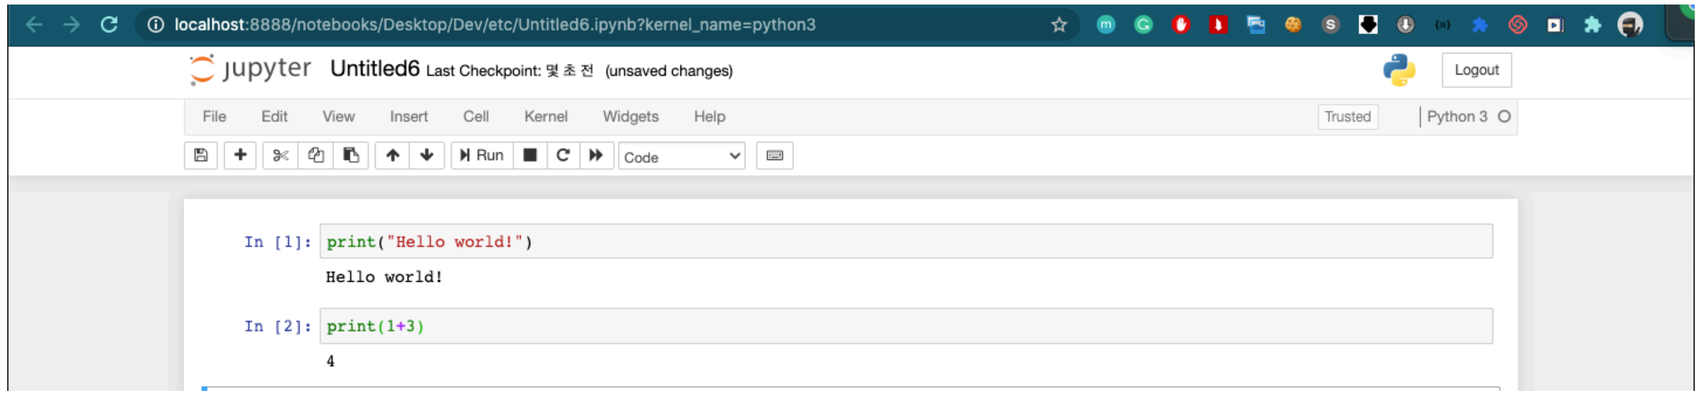

E.O.D